



# VORHERSAGE VON FLUGVERSPÄTUNG

Tim Georg, Lyle Braunbart, Enna-June Irmischer



# Business Understanding

- Problem: Airlines haben oft Verspätungen, welche zu spät erkannt werden.
- Probleme:
  - Gate-Planung erschwert
  - Crew-Planung ineffizient
  - Passagiere unzufrieden
  - Kosten steigen
- Businessproblem: Turnaround am Flughafen von United Airlines verbessern
- Turnaround: Zeit zwischen Landung und erneutem Abflug eines Flugzeugs
- ML-Problem: Wahrscheinlichkeit einer Flugverspätung frühzeitig vorhersagen
- Binäre Klassifikation: Pünktlich und mehr als 14 Minuten verspätet
- Zielvariable: delay\_label = 1 (mehr als 14 Minuten verspätet) sonst 0 (pünktlich)

# Data Understanding

- Datensatz des Flughafens IAD Washington von Januar 2025 bis April 2026
  - BTS TranStats – On-Time Performance

| Datei                                                      | Größe      | Zeilen | Spalten |
|------------------------------------------------------------|------------|--------|---------|
| <code>data/raw/Detailed_Statistics_Arrivals.csv</code>     | 4,903.5 KB | –      | –       |
| <code>data/raw/Detailed_Statistics_Cancellation.csv</code> | 12.5 KB    | –      | –       |
| <code>data/raw/Detailed_Statistics_Departures.csv</code>   | 4,925.5 KB | –      | –       |
| <code>data/raw/Detailed_Statistics_Diversion.csv</code>    | 5.3 KB     | –      | –       |

- Data Ordner in Projektstruktur mit raw und processed Ordner

```
ISE-02-Mini-Case/  
├─ data/  
│   ├── raw/      # Heruntergeladene Monats-CSVs  
│   └─ processed/ # Gefilterte/vereinigte Daten
```

# Data Understanding

- Erste Statistiken und Auffälligkeiten identifiziert:
  - Departure:

### Klassen-Verteilung (Delay $\geq 15$ Min):

| Klasse    | Bedeutung                     | Anzahl | Anteil                 |
|-----------|-------------------------------|--------|------------------------|
| 1         | Verspätet ( $\geq 15$ Min)    | 7,402  | 15.7 %                 |
| 0         | Pünktlich ( $< 15$ Min)       | 39,815 | 84.3 %                 |
| (negativ) | Davon verfrüht ( $< 0$ Min)   | 30,414 | 64.4 % der Gesamtflüge |
| NaN       | Missing (storniert/diverted?) | 0      | 0.0 %                  |

**Verspätungs-Verteilung (Minuten, alle Flüge):**

| Kennzahl   | Wert    |
|------------|---------|
| Mittelwert | 10.08   |
| Median     | -3.00   |
| Std.-Abw.  | 46.25   |
| Min        | -24.00  |
| Max        | 1128.00 |

| Problem                 | Wert                 | Implikation                                  |
|-------------------------|----------------------|----------------------------------------------|
| tail_number Missing     | 330 / 47,217 (0.7 %) | Feature nicht nutzbar                        |
| departure_delay_min NaN | 0 (0.0 %)            | Diese Zeilen für Klassifikation ausschließen |

# Data Understanding

- Erste Statistiken und Auffälligkeiten identifiziert:
  - Arrival:

## Klassen-Verteilung Arrival Delay ( $\geq 15$ Min):

| Klasse    | Bedeutung                           | Anzahl | Anteil                 |
|-----------|-------------------------------------|--------|------------------------|
| 1         | Verspätete Ankunft ( $\geq 15$ Min) | 7,652  | 16.2 %                 |
| 0         | Pünktliche Ankunft ( $< 15$ Min)    | 39,560 | 83.8 %                 |
| (negativ) | Davon verfrüht ( $< 0$ Min)         | 31,362 | 66.4 % der Gesamtflüge |

## Verspätungs-Verteilung bei Ankunft (Minuten):

| Kennzahl   | Wert    |
|------------|---------|
| Mittelwert | 2.66    |
| Median     | -8.00   |
| Std.-Abw.  | 48.32   |
| Min        | -68.00  |
| Max        | 1389.00 |

# Data Understanding

- Datenqualität:
  - Kaum fehlende Werte
  - Delay vollständig vorhanden
  - Tail number: 99% fehlt → Nicht nutzbar
- Auffälligkeiten:
  - Große Streuung
  - Extreme Ausreißer
  - Viele negative Werte → verfrühte Flüge
- Features: Datum, Abflugzeit, Ziel-Flughafen, geplante Flugdauer

# Data Preparation

-

# Modeling

- Modelltyp: Klassifikation
- Modelle: Gradient Boosting /XGBoost oder Random Forest
- Metriken: Recall, Precision und F1-Score
- Risiken: Overfitting, Klassenungleichgewicht

# Evaluation

- Metriken: Recall, Precision und F1-Score
- Risiken: Overfitting, Klassenungleichgewicht

# Deployment



# **VIELEN DANK FÜR DIE AUFMERKSAMKEIT!**

Tim Georg, Lyle Braunbart, Enna-June Irmischer

